Clasificador binario para la predicción del incumplimiento de órdenes de compra en la agroindustria de la palma de aceite

Daniel Carbonó y **Luis Pérez**

Maestría en Estadística Aplicada, Universidad del Norte, 2026

Un grupo agroindustrial colombiano de la palma de aceite: 406.126 posiciones de orden de compra, 2021-2026

Repositorio	https://github.com/ddcarbono/otif-compras-ml
Libro	https://ddcarbono.github.io/otif-compras-ml/
Tablero	pendiente

Estimamos la probabilidad de que cada posición llegue tarde y decidimos con un umbral elegido en validación

Cada fila es una **posición de orden de compra**, observada el día en que la orden sale hacia el proveedor.

$$x_i \in \mathbb{R}^{136}$$

predictoras conocidas en la fecha de liberación t_i

$$y_i \in \{0, 1\}$$

y_i = 1 si la primera entrada de mercancía llega más de 1 día hábil después de la fecha prometida

$$p(x) = \mathrm{P}(y = 1 \mid x)$$

probabilidad de llegar tarde, que se estima

$$\hat{y} = 1 \text{ si } \hat{p}(x) \geq \tau$$

el umbral τ se elige en validación (2025), no en prueba

Tarea: clasificación binaria supervisada.

Por qué binaria: la decisión del comprador es una: dar seguimiento a la orden o no hacerlo.

Magnitud: 33,0 % de las posiciones llega tarde.

Objetivo general: ordenar las posiciones por riesgo de retraso y señalar cuáles atender primero.

Objetivos específicos:

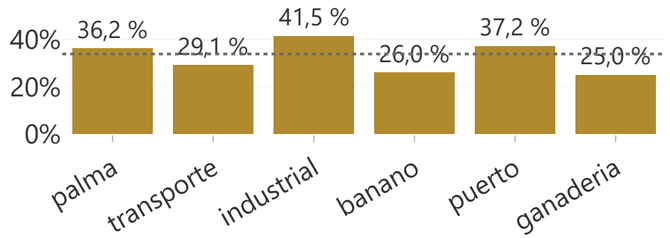
- comparar 7 modelos con 4 formas de balancear y 4 optimizadores de hiperparámetros;
- medir el costo de decidir con entidades nuevas (proveedor o material sin historia).

Fuente: libro, capítulo 02a_datos (definición de la etiqueta y de la población)

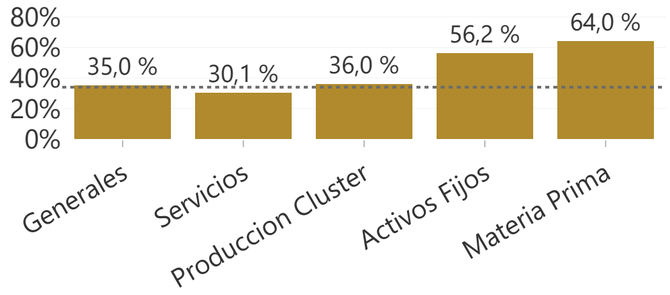
Ninguna variable ordena sola por encima de 0,75 de AUC: la señal está repartida entre plazo, historial y entidad

SAP
compras, 2021-2026
›
490.310 posiciones
filtro: compras con plazo
›
406.126 posiciones
población
›
etiqueta tarde / a tiempo
entrada > 1 día hábil
›
136 predictoras
solo lo conocido al liberar

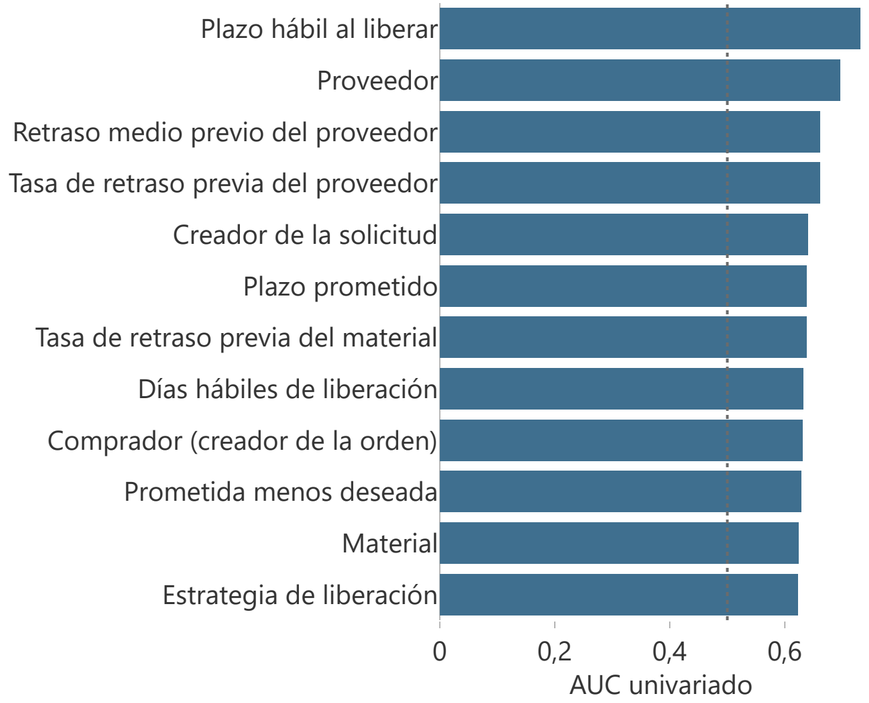
Tasa de tarde por línea (punteada: global)



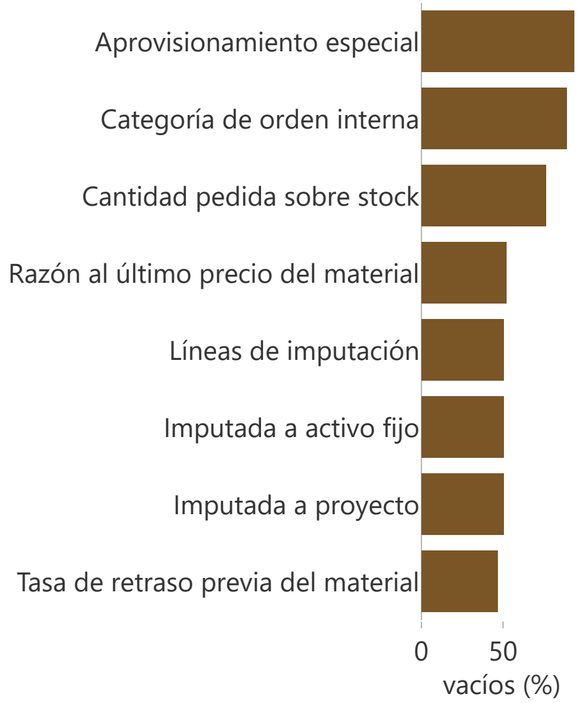
Tasa por clase de compra (punteada: global)



AUC univariado, 12 mayores



Vacíos estructurales (%)

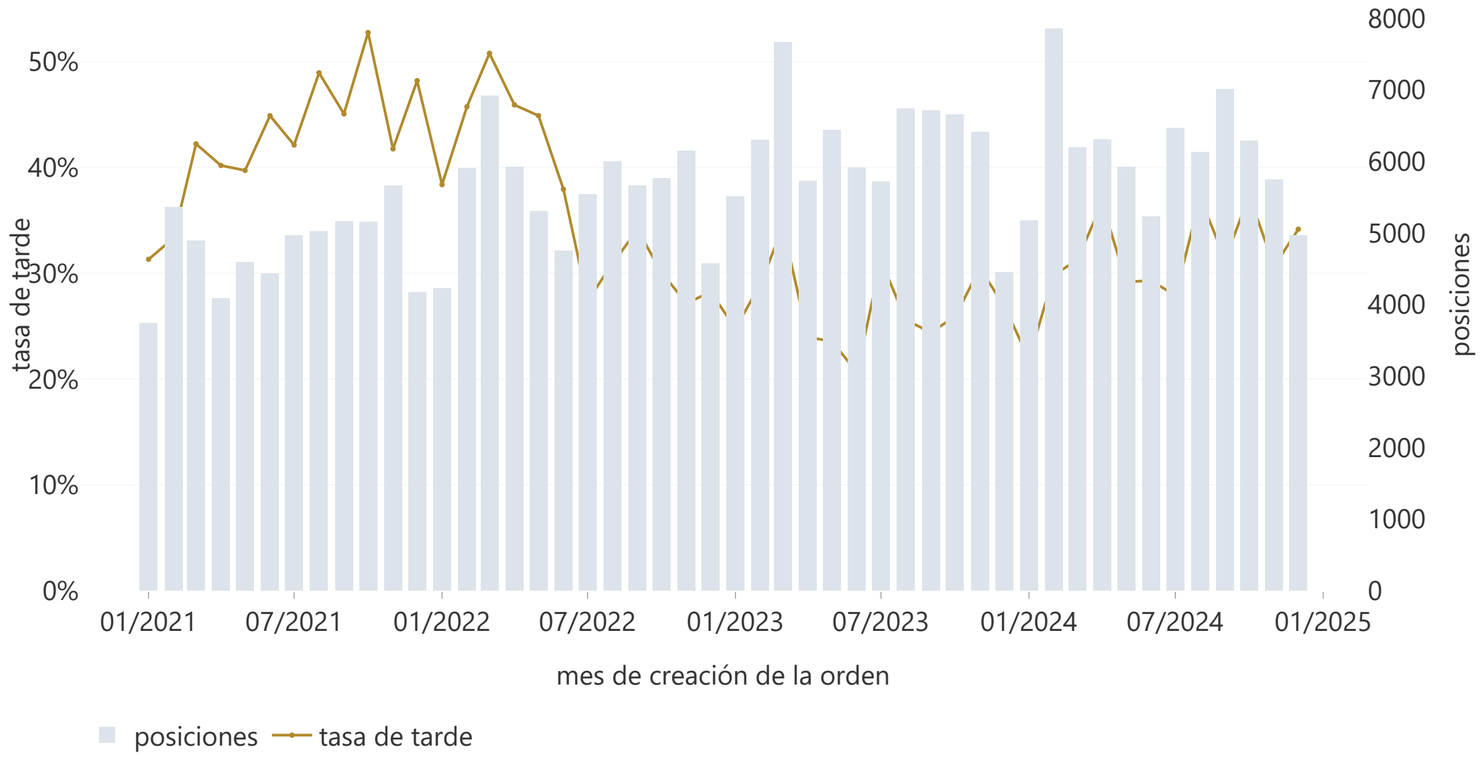


7 variables con más de 50 % de vacíos; son estructurales (sin solicitud de pedido o sin imputación), no azar. Atípicos por Isolation Forest: 40,4 % de tarde contra 33,7 % en el resto. La cantidad tiene asimetría 109: para los modelos lineales conviene transformar con logaritmo. Máximo AUC univariado: 0,732.

Fuente: libro, capítulos 02a_datos y 02b_eda

La tasa de retraso se mueve en el tiempo, por eso se parte cronológicamente y nunca al azar

Tasa de tarde y volumen por mes



Tasa de tarde por partición

2021-2024: 34,0 %

2025: 30,8 %

2026: 31,5 %

Estacionariedad de la serie

ADF (raíz unitaria): p = 0,699

KPSS (estacionaria): p = 0,026

las dos pruebas apuntan a que la tasa no es estable en el tiempo

Entidades nuevas

proveedores nuevos: 6,6 % en 2025 y 11,1 % en 2026

Una partición aleatoria mezclaría el futuro con el pasado y daría un AUC optimista. Además, las posiciones recientes tienen la etiqueta sin madurar (censura al final del periodo).

Fuente: libro, capítulos 02b_eda y 02c_tiempo_y_fuga

El boosting minimiza la log-pérdida paso a paso con árboles; la logística hace lo mismo con una sola recta y un óptimo

Mejor benchmark: boosting de árboles (hoy LightGBM; puede cambiar con los 112)

$$\ell(y, F) = -[\, y \log p + (1 - y) \log(1 - p) \,]$$

log-pérdida sobre el puntaje $F(x)$, con $p = 1 / (1 + e^{-F})$; es convexa en F

$$F_m = F_{m-1} + \eta\, f_m,\ g_i = p_i - y_i,\ h_i = p_i(1 - p_i)$$

descenso por gradiente en el espacio de funciones: cada árbol f_m ajusta gradiente g y curvatura h; η = tasa de aprendizaje

$$\text{Obj} = \Sigma_i\, \ell_i + \Sigma_m\, [\, \gamma\, T_m + \tfrac{1}{2}\, \lambda\, \| w_m \|^2 + \alpha\, \| w_m \|_1 \,]$$

T = hojas, w = valores de hoja; peso óptimo de una hoja (sin L1): $w^* = -G / (H + \lambda)$, con $G = \Sigma g$ y $H = \Sigma h$ de la hoja

Regularización: tasa de aprendizaje η, número de hojas, mínimo de filas por hoja, λ (L2), α (L1), submuestreo de filas y columnas, parada temprana.

Complejidad: árbol por histograma (columnas en bins): construir un árbol cuesta O($n \cdot p$) más la búsqueda de cortes O($bins \cdot p$); predecir cuesta O($M \cdot$profundidad).

Contraste: regresión logística

$$\min_\beta \Sigma_i\, \ell(y_i, x_i^{\mathrm{T}} \beta) + (1 / 2C)\, \|\beta\|^2$$

pérdida convexa: un solo óptimo; log-odds lineal en x; C controla la penalización L2 (o L1). No captura interacciones ni no linealidades sin construirlas.

El boosting corrige lo que la recta no ve (interacciones, umbrales) y paga con más hiperparámetros y riesgo de sobreajuste.

Fuente: libro, capítulo de modelos (en preparación); Friedman (2001), Chen y Guestrin (2016)

Cada una de las 112 combinaciones se evalúa con el mismo presupuesto, hacia adelante en el tiempo

partición	uso	posiciones	órdenes	tarde
2021-2024	entrenar	271.391	70.233	34,0 %
2025	validar, umbral τ	82.794	21.797	30,8 %
2026	probar (una vez)	51.941	12.584	31,5 %

Validación anidada

- bucle externo: 8 bloques semestrales, cada uno se predice con lo anterior;
- bucle interno: el último semestre de cada ventana elige hiperparámetros;
- mismo presupuesto de optimización para todos; una sola semilla.

112 combinaciones

$$7 \text{ modelos} \times 4 \text{ balanceos} \times 4 \text{ optimizadores} = 112$$

Optimizadores

- Optuna: TPE con mejora esperada, aprende de los ensayos previos;
- genética: selección, cruce, mutación y elitismo.

Fuente: libro, capítulos 02a_datos y 02c_tiempo_y_fuga; plan de entregables

LightGBM supera a la logística en 0,06 de AUC con las cifras de hoy (provisionales)

Prueba 2026 cifra provisional

modelo	AUC	F1 (τ de 2025)
regla del proveedor	0,670	0,509
logística	0,794	0,618
LightGBM + Platt	0,852	0,678

Un solo ajuste por modelo; cambia con los 112 y su validación anidada.

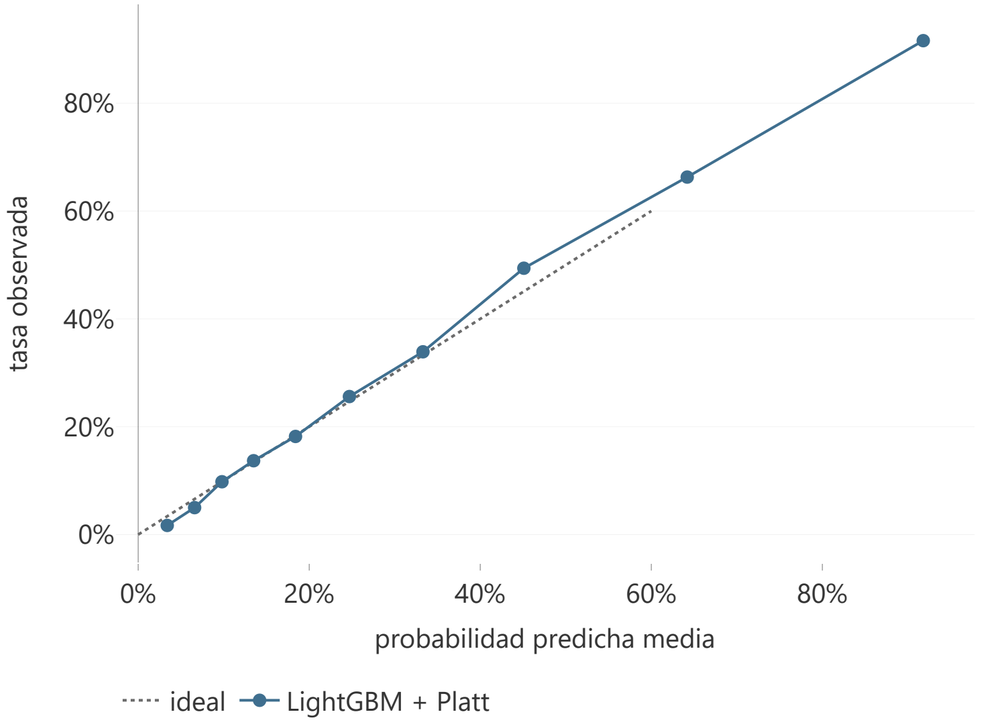
pendiente
curvas de optimización: AUC contra evaluaciones y contra tiempo, por optimizador (resultados de los 112)

pendiente
tabla de líderes y diagrama de diferencia crítica (DeLong, Holm, delta de Cliff)

Fuente: libro, capítulo de resultados (pendiente); modelar_otif.txt para las cifras provisionales

Con entidades nuevas el AUC baja de 0,860 a 0,823: el costo del arranque en frío (provisional)

Calibración por decil (provisional)



AUC de LightGBM en 2026 cifra provisional

todo conocido	0,860
con algún valor nuevo	0,823

pendiente

matriz de confusión por línea; brecha entre entrenamiento y validación por iteración (sobreajuste); SHAP del mejor modelo

Fuente: libro, capítulo de resultados (pendiente); modelar_otif.txt para las cifras provisionales

El retraso se anticipa mejor que con la regla del proveedor, con límites claros de periodo, maestros y entidades nuevas

Conclusiones

- El incumplimiento se puede anticipar el día de la liberación: 0,852 de AUC y 0,678 de F1 en 2026 (regla del proveedor: 0,670 de AUC) cifra provisional.
- El plazo, el historial del proveedor y las entidades concentran la señal; ninguna variable sola pasa de 0,75 de AUC.
- La partición cronológica y la validación anidada son lo que hace creíble el número.
- Veredicto sobre los 112 modelos: pendiente.

Limitaciones

- Censura al final del periodo: las posiciones recientes tienen la etiqueta sin madurar.
- Los maestros (proveedor, material) están en foto actual, no con vigencia histórica.
- Una sola empresa: la generalización a otros grupos no está probada.
- Entidades nuevas (11,1 % de proveedores nuevos en 2026): el modelo no tiene historia que usar.

Fuente: libro, capítulos 02a_datos, 02b_eda y 02c_tiempo_y_fuga; modelar_otif.txt (cifras provisionales)