

UNIVERSIDAD DEL NORTE

Maestría en Estadística Aplicada

Machine Learning

Daniel Carbonó Domínguez

Luis Pérez

Octubre de 2026

CLASIFICACIÓN BINARIA SUPERVISADA

Predicción del incumplimiento de órdenes de compra en la agroindustria de la palma de aceite

406.126 posiciones de 104.614 órdenes de compra, 2021-2026

Repositorio github.com/ddcarbono/otif-compras-ml

Libro ddcarbono.github.io/otif-compras-ml

Tablero otif-compras-ml.onrender.com

Uno de cada tres pedidos llega tarde, y se sabe cuando ya pasó

CRITERIO 1 · EL PROBLEMA

33,0 %
de las posiciones llega tarde

41 %
en industrial; 25 % en ganaderia

71 %
de las tardías de 2026, marcando el 38 %

Por qué importa

El comprador hoy se entera del retraso cuando la mercancía no llega. Con miles de posiciones abiertas, no puede seguirlas todas: necesita saber, el día en que libera la orden, cuáles vigilar.

Qué dice la literatura

En fabricantes de maquinaria y equipos llega tarde del 13 % al 14 % de los pedidos (Brintrup y otros, 2020; Steinberg y otros, 2023): aquí es más del doble.

Una revisión de 26 estudios encuentra que 16 parten las filas al azar; reevaluado sin fuga y en el tiempo, un AUC de 0,96 baja a 0,73 (Raval, 2026). Este trabajo evalúa siempre hacia adelante.

Objetivos

General: ordenar las posiciones por riesgo de retraso el día de la liberación y señalar cuáles seguir.
Específico 1: comparar 7 modelos × 4 balanceos × 4 optimizadores con el mismo presupuesto.
Específico 2: medir cuánto cuesta decidir con entidades nuevas (proveedor o material sin historia).
Específico 3: dejar el modelo servido en un tablero con predicción en vivo.

Fuente: libro, introducción y literatura; capítulo 5 (modelo base): data/modelos/metricas.csv

Estimar la probabilidad de llegar tarde y decidir con un umbral

CRITERIO 1 · FORMULACIÓN MATEMÁTICA

Unidad: la posición i, el día t en que se libera su orden

$$x_i \in \mathbb{R}^{136}, \quad y_i \in \{0, 1\}$$

x: 136 predictoras conocidas en t. y = 1 si la primera entrada de mercancía llega más de 1 día hábil después de la fecha prometida vigente al liberar.

El modelo estadístico: y | x es Bernoulli con probabilidad p(x)

$$p(x) = P(y = 1 \mid x), \qquad \hat{y} = \mathbb{1}\{\hat{p}(x) \geq \tau\}$$

Se estima p(x) minimizando la log-pérdida, que es menos la log-verosimilitud de Bernoulli; la decisión ŷ compara p̂ con un umbral τ.

$$\ell(y, F) = -\log\left[\hat{p}^{\,y}(1 - \hat{p})^{1-y}\right], \qquad \hat{p} = \sigma(F)$$

El umbral τ se elige en la validación 2025, maximizando F1; la prueba 2026 se usa una sola vez y no elige nada.

Métricas: AUC para ordenar por riesgo (no depende de τ) y F1 para la decisión.

Tarea

Clasificación binaria supervisada: la etiqueta se observa después, cuando entra la mercancía, y el modelo aprende de las órdenes ya cerradas.

Por qué no regresión

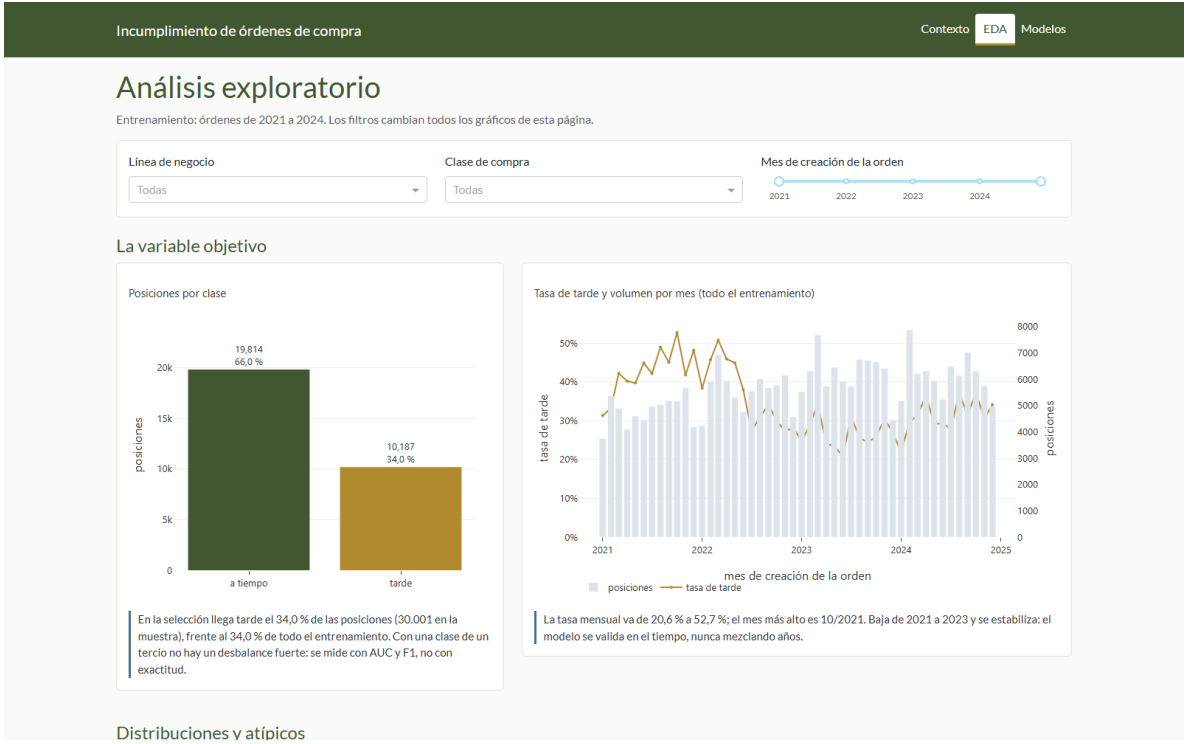
La decisión del comprador es binaria: seguir la orden o no. Los días de retraso tienen colas muy largas y se usan como contexto; el modelo original del Entregable 3 los aprovecha con cortes ordenados.

Fuente: libro, capítulos 1 y 2 (definición de la etiqueta y de la población)

Tablero: el contexto y la exploración, con filtros

CRITERIO 2 · PANTALLA EN VIVO

captura de respaldo, por si el tablero no carga



EN VIVO

otif-compras-ml.onrender.com

1. Contexto: la fuente (SAP, 2021-2026), la población y la etiqueta.
2. EDA: el objetivo por clase y la tasa por mes.
3. Filtrar una línea de negocio: todo cambia con ella (de 25 % a 41 % de tarde).
4. Bajar a distribuciones y atípicos.

Fuente: tablero, páginas Contexto y EDA (otif-compras-ml.onrender.com)

De SAP a 406.126 posiciones con una etiqueta y 136 predictoras

CRITERIO 2 · FUENTE, ESTRUCTURA Y PARTICIÓN

SAP
compras 2021-2026

490.310
posiciones con plazo

406.126
población

etiqueta
> 1 día hábil tarde

136
predictoras al liberar

partición	uso	posiciones	órdenes	tarde
2021-2024	entrenar	271.391	70.233	34,0 %
2025	elegir umbral	82.794	21.797	30,8 %
2026	probar una vez	51.941	12.584	31,5 %

Las órdenes son la unidad independiente: 3,9 posiciones por orden. Ninguna orden cruza particiones y toda validación cruzada agrupa por orden.

La partición es por la fecha de la orden, no al azar (diapositiva 8).

Las 136 predictoras

83 numéricas: plazo, valor, liberación, historial del proveedor, stock, tasa de cambio.
42 categóricas de pocos valores: línea, clase, moneda, tipo de material.
11 entidades: proveedor, material, comprador, liberador, centro de costo y otras.
Solo lo que se conoce el día de la liberación.

Fuente: libro, capítulo 2 (datos); diccionario de variables en data/diccionario.csv

Colas largas, vacíos con causa y atípicos que llegan más tarde

CRITERIO 2 · DESCRIPTIVA, FALTANTES Y ATÍPICOS

variable	mediana	p99	asimetría
Valor para la liberación	24.807,3	6.967.970	294,2
Precio de la solicitud	499,0	364.340	247,5
Razón cantidad orden/solicitud	1,0	1	238,5
Razón al último precio del material	1,0	6	213,5
Razón precio orden/solicitud	1,0	78.327	190,0
Plazo original al crear	20,0	177	148,7

Por eso signo(x)·log(1 + |x|) antes de los modelos lineales: comprime las colas sin cambiar el orden. A los árboles no les cambia nada, porque solo usan el orden.

Atípicos multivariados (Isolation Forest)

40,4 % de tarde en las atípicas contra 33,7 % en el resto: son señal, no ruido, y no se borran.

variable	vacíos	Δ tasa (pp)
mc_aprov_especial	93,6 %	0,3
imp_categoria_orden	88,8 %	-0,3
razon_cantidad_stock	76,3 %	2,3
mat_razon_ultimo_precio	51,9 %	-0,8
imp_n	50,3 %	2,9
imp_a_activo	50,3 %	2,9

Faltantes estructurales

7 variables con más de 50 % de vacíos, y no son azar: faltan porque la orden no tiene solicitud o no tiene imputación. Se marcan con indicadores tiene_* y se imputa la mediana; Δ tasa es la diferencia de retraso entre filas con y sin dato.

Fuente: libro, capítulo 3 (EDA): resultados/eda/univariado_numericas.csv, faltantes.csv, atipicos_if.csv

Ninguna variable sola pasa de 0,75 de AUC, y ninguna es fuga

CRITERIO 2 · RELACIONES Y FUGA



El plazo hábil al liberar separa más (0,732): es la causa más directa del retraso y se conoce al liberar.

Auditoría de fuga

Cada grupo de variables, revisado contra el día de la liberación. Retiradas: los días de retraso, las fechas de entrada y de factura, los cambios de fecha posteriores y los maestros que el planificador ajusta después de ver retrasos.

Entidades: tasa encogida hacia su nivel superior

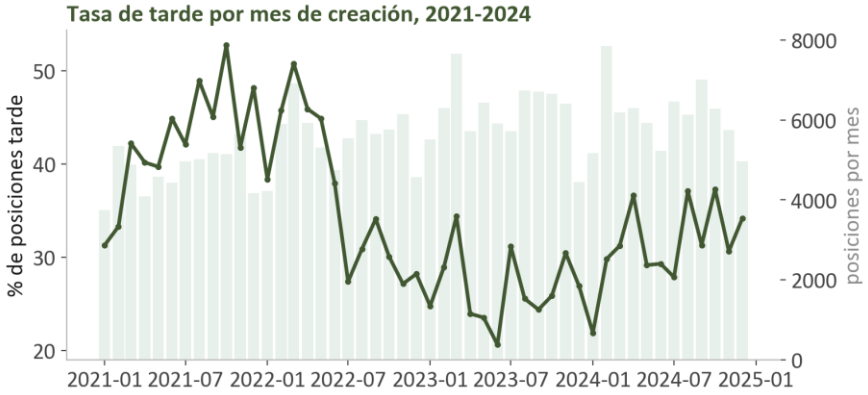
$$\hat{p}(v) = \frac{\text{retrasos}(v) + M\hat{p}(\text{padre}(v))}{n(v) + M}, \quad M = 20$$

Se calcula fuera de pliegue y agrupada por orden: una posición no ve su propio objetivo ni el de su orden. Un valor nuevo recibe la tasa de su padre (el proveedor, la de su región).

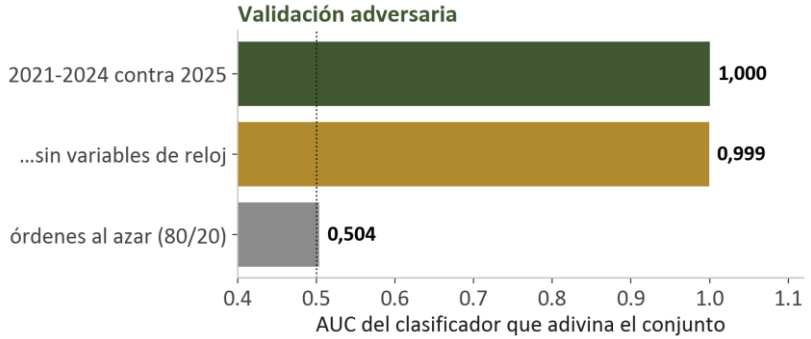
Fuente: libro, capítulos 3 y 4: resultados/eda/asociacion.csv; src/datos.py

El tiempo importa: partir al azar mediría con datos ya vistos

CRITERIO 2 · DERIVA Y PARTICIÓN



No es estacionaria: ADF no rechaza la raíz unitaria (p = 0,70) y KPSS rechaza la estacionariedad (p = 0,026). Proveedores nuevos: 6,6 % en 2025 y 11,1 % en 2026.



Validación adversaria: un XGBoost intenta adivinar de qué conjunto viene cada posición.

Al azar no puede (0,504). Por fecha acierta siempre (1,000), y sigue en 0,999 sin las variables que fechan la fila: muchas derivas pequeñas (IVA, región del centro, mezcla de líneas) bastan para reconocer el año.

Por eso: partición cronológica, validación por ventanas crecientes y reentrenar con 2021-2025 antes de la prueba.

Fuente: libro, capítulo 4 (tiempo y fuga): resultados/eda/ y resultados/similitud/auc.csv

XGBoost: el log-odds como suma de árboles

CRITERIO 3 · FORMULACIÓN DEL ALGORITMO

El modelo

$$F(x) = \sum_{m=1}^{M} f_m(x), \qquad \hat{p}(x) = \sigma(F(x)) = \frac{1}{1+e^{-F(x)}}$$

Cada árbol f_m reparte el espacio de las predictoras en T hojas y da a cada hoja un peso w_j. Los árboles se construyen en secuencia: el m corrige lo que los m − 1 anteriores todavía predicen mal.

La pérdida: menos la log-verosimilitud de Bernoulli

$$\ell(y, F) = -y \log \sigma(F) - (1-y)\log(1-\sigma(F))$$

Es convexa en F y penaliza sin límite una probabilidad segura y equivocada: por eso produce probabilidades, no solo un orden.

El principio: descenso por gradiente en el espacio de funciones

En vez de mover parámetros, cada iteración agrega una función (un árbol) en la dirección que más baja la pérdida (Friedman, 2001). XGBoost usa además la curvatura: un paso de Newton (Chen y Guestrin, 2016).

Boosting

Árboles en secuencia, cada uno sobre los errores del anterior: baja el sesgo. Pide regularización para no sobreajustar.

Bosque aleatorio

Árboles independientes y promediados: baja la varianza. Fue el segundo de los 112; la diferencia está en corregir el error en vez de promediarlo.

Fuente: libro, capítulo 8 (fundamentos); Friedman (2001), Chen y Guestrin (2016)

Cada árbol minimiza una aproximación de segundo orden

CRITERIO 3 · PRINCIPIO DE OPTIMIZACIÓN

El objetivo del árbol m: la pérdida más una penalización de su complejidad

$$\mathcal{L}^{(m)} = \sum_{i=1}^{n} \ell(y_i,\, F_{m-1}(x_i) + f(x_i)) + \gamma T + \tfrac{1}{2}\lambda \sum_{j=1}^{T} w_j^2$$

Taylor de segundo orden alrededor de la predicción actual F_{m−1}

$$\mathcal{L}^{(m)} \approx \sum_{i} \left[g_i f(x_i) + \tfrac{1}{2} h_i f(x_i)^2 \right] + \gamma T + \tfrac{1}{2}\lambda \sum_{j} w_j^2$$

Gradiente y hessiano de la log-pérdida: la derivación

$$\sigma'(F) = \sigma(1-\sigma) \;\Rightarrow\; \frac{\partial \ell}{\partial F} = -y(1-\sigma) + (1-y)\,\sigma = \sigma - y, \qquad \frac{\partial^2 \ell}{\partial F^2} = \sigma(1-\sigma)$$

$$g_i = \hat{p}_i - y_i, \qquad h_i = \hat{p}_i\,(1-\hat{p}_i)$$

g_i, el gradiente

El residuo con signo: positivo si el modelo sobreestima el riesgo de una posición que llegó a tiempo.

h_i, el hessiano

La varianza de Bernoulli: grande donde el modelo duda (p̂ cerca de 0,5) y pequeño donde ya está seguro.

Fuente: libro, capítulo 8; Chen y Guestrin (2016)

Peso de hoja y ganancia de corte en forma cerrada

CRITERIO 3 · CÓMO SE CONSTRUYE CADA ÁRBOL

Peso óptimo de la hoja j

$$w_j^* = -\frac{G_j}{H_j + \lambda}$$

Con G_j y H_j la suma de g y h en la hoja, la aproximación es una parábola en w_j: su mínimo es un paso de Newton, el gradiente sobre la curvatura, encogido por λ.

Búsqueda por histograma (hist)

Cada predictora se discretiza en a lo sumo 256 tramos y la ganancia se evalúa solo en sus bordes: buscar el mejor corte es recorrer un histograma, no ordenar las filas.

Ganancia de partir una hoja en izquierda (L) y derecha (R): se corta solo si es positiva

$$\text{ganancia} = \frac{1}{2}\left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda}\right] - \gamma$$

Paso corto: cada árbol entra encogido por la tasa de aprendizaje

$$F_m = F_{m-1} + \eta f_m$$

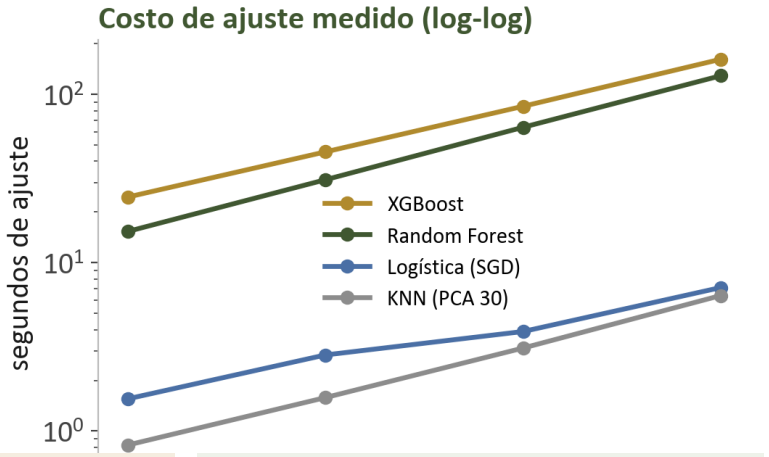
Contraste: la logística minimiza la misma log-pérdida con una sola recta, convexa y con un único óptimo. No ve interacciones ni umbrales sin construirlos; XGBoost los encuentra con los cortes.

Fuente: libro, capítulo 8; Chen y Guestrin (2016)

El ajuste crece casi lineal en n (exponente 0,91)

CRITERIO 3 · SUPUESTOS, REGULARIZACIÓN, COMPLEJIDAD Y GENERALIZACIÓN

hiperparámetro	en la fórmula	qué controla
n_estimators	M	capacidad y costo
learning_rate	η	pasos cortos, mejor generalización
max_depth	T ≤ 2^D	interacciones de hasta D variables
min_child_weight	H_j ≥ c	hojas con suficiente evidencia
subsample, colsample	filas y columnas	azar que decorrelaciona árboles
reg_lambda, gamma	λ, γ	encoge pesos, cobra hojas



Supuestos

Filas independientes dado x (por eso los pliegues agrupan por orden); la relación de 2021-2025 sigue valiendo en 2026; no supone linealidad ni normalidad.

Complejidad

Ajuste O(M·D·n·d') por histograma; predicción O(M·D). Medido: 162 s con 311.865 filas; 16,8 ms por cada 1.000 predicciones.

Generalización

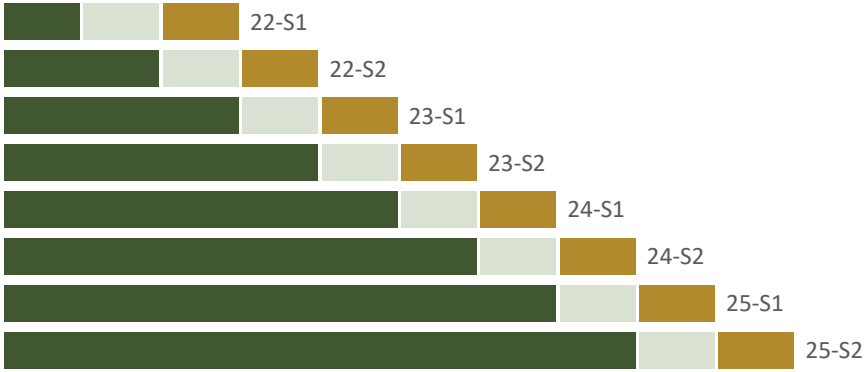
Regularización más validación por ventanas en el tiempo; una entidad nueva recibe la tasa de su nivel superior.

Fuente: libro, capítulo 8: resultados/complejidad.csv (tiempos medidos en srvgdai)

Hacia adelante en el tiempo, con el mismo presupuesto

CRITERIO 4 · DISEÑO EXPERIMENTAL

$$7 \times 4 \times 4 = 112 \text{ combinaciones} \times 8 \text{ bloques} = 896 \text{ trabajos}$$



verde: entrena gris: valida adentro (elige hiperparámetros) **oro: evalúa (bucle externo)**

Bucle externo: 8 semestres, cada uno predicho con todo lo anterior. Bucle interno: el último semestre de cada ventana elige los hiperparámetros. La prueba 2026 no entra en nada de esto.

4 balanceos

Ninguno, SMOTE, ADASYN y pesos de clase, siempre dentro del pipeline y solo sobre el entrenamiento de cada ventana: lo sintético nunca llega a la evaluación.

4 optimizadores, mismo presupuesto

20 evaluaciones por combinación y bloque para Grid, Random, Optuna (TPE) y DEAP (genético). Medias y desviaciones salen de los 8 bloques externos.

Fuente: libro, capítulo 6 (las 112): src/validacion.py, src/experimentos.py

Implementación: un pipeline, un espacio de búsqueda y pruebas

CRITERIO 4 · IMPLEMENTACIÓN E HIPERPARÁMETROS

hiperparámetro	espacio	elegido (8 bloques)
n_estimators	100 a 600	266 a 587
learning_rate	0,01 a 0,3 (log)	0,02 a 0,12
max_depth	3 a 10	4 a 10
subsample	0,5 a 1	0,52 a 0,94
colsample_bytree	0,3 a 1	0,31 a 0,86
min_child_weight	1 a 100 (log)	8,91 a 38,19

Con un semestre de entrenamiento gana un modelo de muchos árboles poco profundos; con más datos la profundidad sube a 7-10 y el submuestreo baja. Cerca del óptimo la superficie es plana: configuraciones distintas dan AUC a milésimas.

Reproducible: semilla 2026; un JSON por trabajo con parámetros y métricas; 201 horas de CPU en el servidor del grupo, 30 trabajos a la vez.

Un solo pipeline de scikit-learn

preprocesador (log, imputación, one-hot, codificación por objetivo) → balanceo → modelo;
el preprocesador se ajusta solo con el entrenamiento de cada ventana.

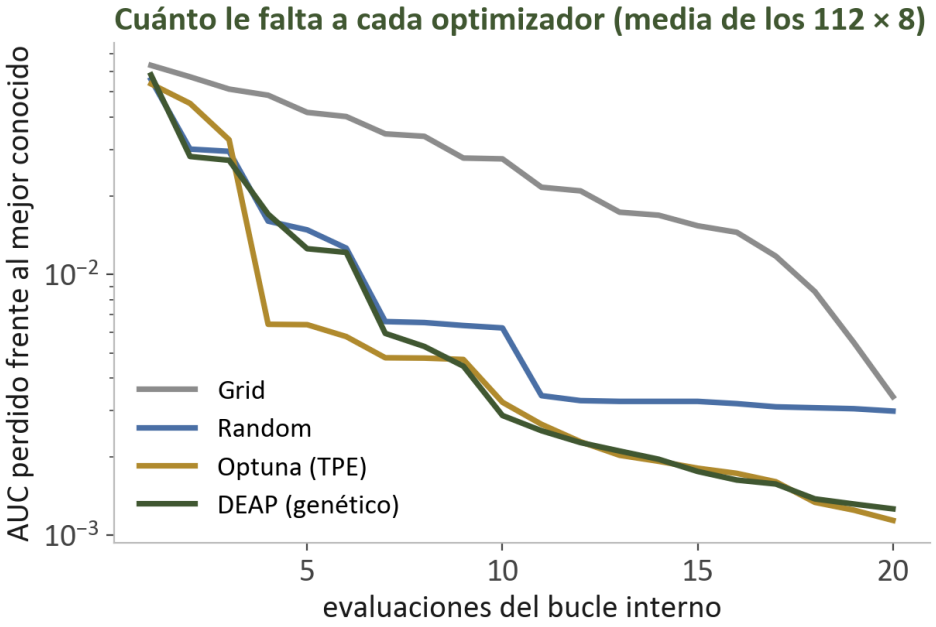
Pruebas e integración continua

57 pruebas con pytest (codificación fuera de pliegue, series, modelo servido, tablero, que no se publiquen identificadores) que corren en GitHub en cada cambio.

Fuente: src/experimentos.py (ESPACIOS), resultados/experimentos/trabajos/*.json, tests/

Optuna llega antes; con 20 evaluaciones empatan los cuatro

CRITERIO 4 · PANTALLA EN VIVO: LAS 112



optimizador	AUC perdido a 5 evaluaciones	a 20
Optuna	0,0064	0,0011
DEAP	0,0125	0,0013
Random	0,0148	0,0030
Grid	0,0417	0,0034

EN VIVO

otif-compras-ml.onrender.com

1. Modelos → Las 112 combinaciones.
2. Tabla de líderes: las mejores combinaciones, con media ± desviación del bucle externo.
3. Mapa balanceo × optimizador de XGBoost: el balanceo casi no mueve el AUC.

Fuente: tablero, página Modelos (otif-compras-ml.onrender.com); data/modelos/curvas_optimizador.csv

XGBoost gana los 8 bloques: AUC 0,852 contra 0,843

CRITERIO 5 · MÉTRICAS, LÍNEA BASE Y COMPARACIÓN

modelo (mejor combinación)	AUC ± desv.	PR-AUC	F1	ms / 1.000
XGBoost · sin balanceo · Optuna	0,852 ± 0,020	0,778	0,676	17,3
Random Forest · SMOTE · Grid	0,843 ± 0,023	0,761	0,660	31,8
Logística (SGD) · pesos · Grid	0,839 ± 0,025	0,751	0,663	0,7
SVM lineal (SGD) · pesos · Random	0,839 ± 0,024	0,749	0,659	0,7
Árbol · sin balanceo · Optuna	0,810 ± 0,020	0,715	0,634	0,8
KNN (PCA 30) · SMOTE · Optuna	0,781 ± 0,044	0,665	0,601	1.414,6
Naive Bayes · SMOTE · DEAP	0,735 ± 0,069	0,566	0,556	29,4

AUC ordena por riesgo sin depender del umbral; PR-AUC atiende a la clase de interés; F1 mide la decisión al umbral; Brier y ECE dicen si la probabilidad es creíble.

prueba 2026	AUC [BCa 95 %]	F1	ECE
regla del proveedor	0,670	0,509	0,055
regresión logística	0,825	0,649	0,021
XGBoost, con Platt	0,848 [0,835; 0,860]	0,675	0,022

Cómo leer la tabla

Media y desviación de los 8 bloques externos: cada cifra se midió en un semestre que el modelo no vio. La línea base son la regla del proveedor (su tasa previa de retraso) y la logística, medidas en 2026. Frente a la logística, con el mismo 20 % de alertas: 35 tardías más por mes, 17 de material sin stock.

De la validación a 2026

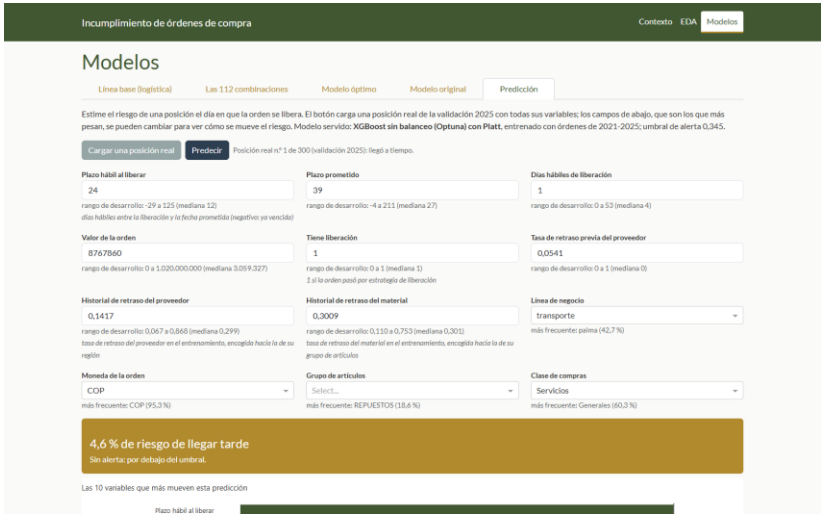
AUC interno 0,854, bloques externos 0,852, prueba 2026 0,848: no cae.

Fuente: libro, capítulos 6 y 7: data/modelos/lideres.csv; resultados/prueba_2026/metricas.csv, brecha.csv, criticas.csv

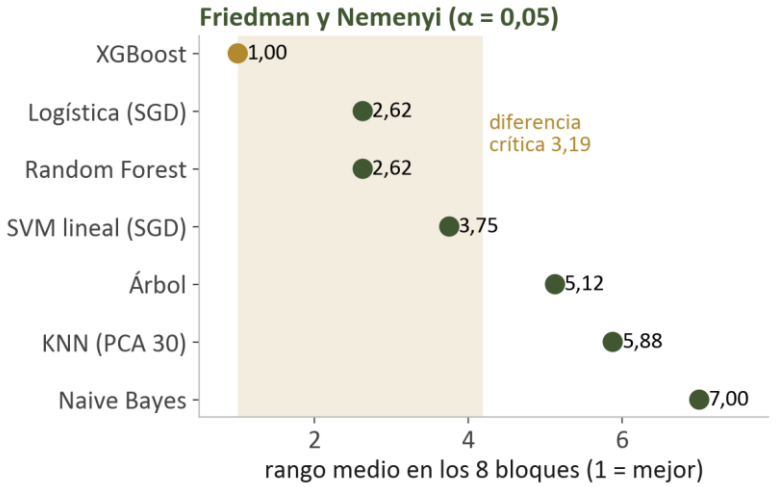
Tablero: una predicción en vivo, y la prueba de diferencias

CRITERIO 5 · PANTALLA EN VIVO

captura de respaldo, por si el tablero no carga



En vivo (Modelos → Predicción): cargar una posición real, cambiar el plazo hábil al liberar y ver cómo se mueven el riesgo y sus contribuciones.



Friedman: $\chi^2 = 45{,}6$, $p < 0{,}001$: los 7 modelos no rinden igual.

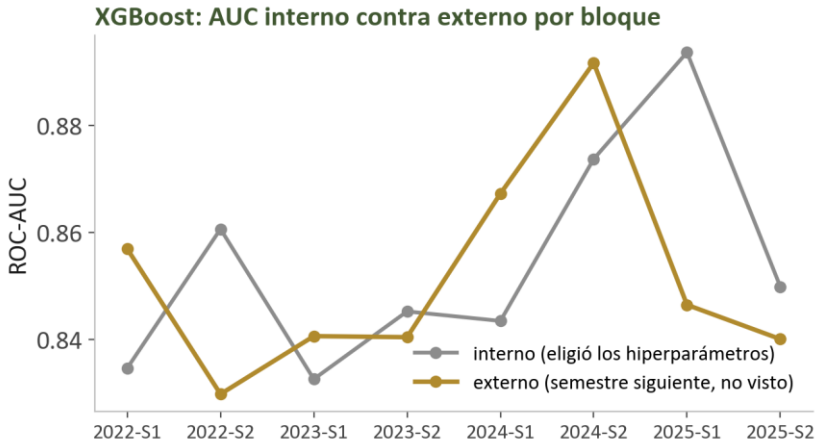
Nemenyi no separa a XGBoost de la logística ni del bosque (diferencia crítica 3,19); Wilcoxon por pares sí: gana los 8 bloques, p de Holm = 0,047.

Dentro de cada bloque, DeLong con Holm: supera al bosque en 6 de 8 y a la logística en 7, sin perder en ninguno. Ventaja 0,009-0,012 de AUC, con BCa por órdenes lejos de cero.

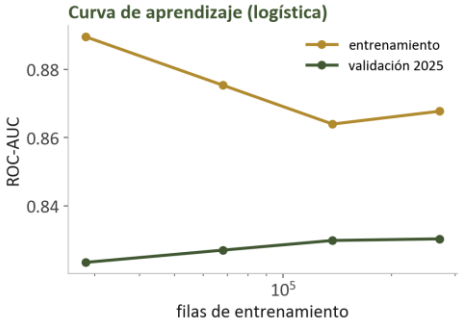
Fuente: tablero, página Modelos; data/modelos/friedman.csv, wilcoxon.csv; resultados/pruebas/resumen.csv

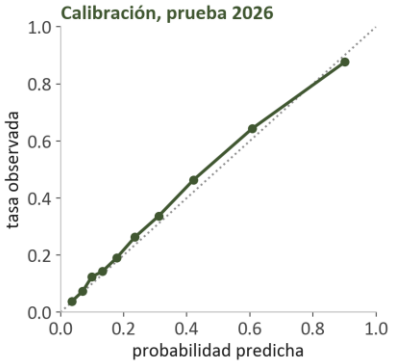
Sobreajuste bajo: 0,003 de AUC entre interno y externo

CRITERIO 5 · ANÁLISIS DE ERRORES Y SOBREAJUSTE



El bloque 2025-S1 baja de 0,894 adentro a 0,846 afuera: es el semestre en que cambia la mezcla de 2025 (diapositiva 8), no un modelo que memoriza.





Logística (modelo base): 0,868 en entrenamiento y 0,830 en validación con todas las filas; bien calibrada en 2026 (ECE 0,021).

Errores de XGBoost en 2026: de 16.374 tardías marcó 11.341 (69 %), con 5.889 falsas alarmas. AUC 0,856 con todo conocido y 0,821 con alguna entidad nueva; ganadería, 0,712. El falso negativo típico tenía plazo amplio y un proveedor puntual: el retraso se decide en la ejecución.

Fuente: libro, capítulos 6 y 7: resultados/experimentos/por_bloque.csv, resultados/prueba_2026/segmentos.csv

El modelo original le gana al óptimo de las 112 por 0,011 de AUC

CRITERIO 6 · MODELO ORIGINAL (ENTREGABLE 3)

BOREAL: efectos por entidad sobre un boosting, con cortes ordenados

$$P(d_i > c \mid x_i) = \sigma\big(f(x_i, c) + b_{\text{prov}} + b_{\text{mat}} + b_{\text{sol}} + b_{\text{comp}}\big), \quad c \in \{0, 1, 5, 15\}, \quad b_e \sim N(0, \sigma_e^2)$$

d_i: días de retraso; se predice en c = 1 (y_tarde) y aprende también de cuánto se atrasó. b_e: intercepto aleatorio por proveedor, material, solicitante y comprador, encogido hacia 0 (σ²_e por EM). Al entrenar, los árboles ven efectos estimados solo con los semestres anteriores, como al predecir.

f es un LightGBM, no un XGBoost

Misma suma de árboles, misma log-pérdida y mismo peso de hoja −G/(H + λ) (diapositiva 11). Difiere en cómo crece el árbol: por hoja, partiendo la de mayor ganancia hasta 154 hojas, y no por niveles (XGBoost: profundidad 10). Aquí toma Σ b_e como desplazamiento fijo del logit y es monótono decreciente en c.

Plazo log-normal y plazo real

$$z_i = \frac{\log(1 + \text{plazo prometido}_i + 1{,}5) - \mu_i}{s}, \qquad \mu_i = E[\log(1 + \text{plazo real}_i)]$$

z: cuánto alcanza la promesa frente al plazo real esperado (un LightGBM sin la promesa). Más 32 variables de plazo real: mediana y percentil 80 de las últimas 20 entregas, y la holgura empírica.

2026, AUC [BCa 95 %]	136 del dataset	136 + 32 nuevas
XGBoost	0,848 [0,835; 0,860]	0,858 [0,846; 0,869]
BOREAL sin log-normal	0,854 [0,841; 0,865]	0,857 [0,843; 0,868]
Propuesta	0,858 [0,845; 0,868]	0,860 [0,847; 0,871]

Lectura de la 2 × 2

Con las 136, la estructura suma 0,009 [0,003; 0,015]. El plazo real le da a XGBoost 0,010 [0,006; 0,014]; con él, la ventaja de la estructura baja a 0,001, sin significancia.
El log-normal suma 0,003; su intervalo toca el cero.

En el tablero: la pestaña Predicción lo sirve con posiciones reales de 2026, sin códigos de entidad. Es la cuarta mirada a 2026: exploratoria. En las órdenes con alguna entidad nueva no gana: el arranque en frío sigue abierto.

Fuente: libro, capítulo 11: resultados/prueba_2026/dos_por_dos.csv y contrastes.csv; tablero: Modelos → Modelo original

En otros datos, la propuesta gana donde hay historia por entidad

CRITERIO 6 · VALIDACIÓN EN CONJUNTOS PÚBLICOS

conjunto	AUC XGBoost	AUC boosting mixto	Δ [IC 95 %]	p Holm	veredicto
Vuelos (Airlines)	0,637	0,633	-0,004 [-0,009; 0,001]	0,217	empate
Acceso (Amazon)	0,867	0,859	-0,008 [-0,017; 0,001]	0,217	empate
Publicidad (Click)	0,707	0,699	-0,007 [-0,013; -0,002]	0,057	empate
Reingreso (Diabetes130US)	0,659	0,676	0,017 [0,009; 0,025]	< 0,001	boosting mixto gana
Citas no asistidas	0,730	0,735	0,005 [0,002; 0,007]	0,002	boosting mixto gana
Buses de Nueva York	0,844	0,852	0,008 [0,005; 0,010]	< 0,001	boosting mixto gana
Transporte de Zúrich	0,830	0,836	0,006 [-0,004; 0,018]	0,217	empate

Mismo protocolo para los dos: Optuna con 20 evaluaciones en validación, una medida en la prueba, DeLong pareado con Holm sobre los siete. La segunda ronda (filas 4 a 7) se eligió con un criterio fijado antes de correr. El plazo log-normal y las variables nuevas no aplican fuera de OTIF.

Lectura

Gana 3, empata 4, pierde 0; Wilcoxon p = 0,69: no hay superioridad general.
Gana donde la entidad vuelve (el paciente, el bus), como el proveedor en OTIF.
Empata con entidades pocas y estables, o sin tiempo ni desenlace continuo.

Cuidado: la segunda ronda se eligió por parecerse a OTIF: dice dónde sirve, no que sea mejor en general.

Fuente: libro, capítulo 12: original/publicos_otif_resumen.csv (OpenML); tablero: Modelos → Modelo original

El retraso se puede anticipar el día de la liberación

CRITERIO 6 · CONCLUSIONES

- Se puede ordenar por riesgo al liberar: AUC 0,852 medido hacia adelante en el tiempo, contra 0,670 de la regla del proveedor en 2026.
- La señal está en el plazo, el historial del proveedor y las entidades; ninguna variable sola basta.
- XGBoost gana de forma significativa y material: en 2026, AUC 0,848 contra 0,825 de la logística, y más tardías atrapadas con las mismas alertas.
- El optimizador importa con poco presupuesto; el balanceo casi no mueve el AUC.
- La partición cronológica no es un detalle: al azar, el problema parecería más fácil de lo que es.

objetivo	cumplido
comparar las 112 con el mismo presupuesto	sí
costo de las entidades nuevas	AUC 0,82 contra 0,86
modelo servido en el tablero	sí, el original (y XGBoost)
modelo original contra el óptimo	+0,011 de AUC [0,003; 0,017]

Para el negocio: marcando el 33 % de las posiciones, XGBoost ve venir el 69 % de las tardías de 2026. Por órdenes: siguiendo el 39 % se ve venir el 69 % de las órdenes con retraso.

Fuente: libro, capítulos 2 a 10

Límites: deriva, etiqueta que madura y una sola empresa

CRITERIO 6 · LIMITACIONES Y MEJORAS

Teóricas

Independencia dado x: las posiciones de una orden se parecen; se protege agrupando, no se modela.
Estabilidad: el modelo supone que la relación de 2021-2025 vale en 2026.
Una sola etiqueta binaria desperdicia los días de retraso.

Empíricas

Deriva: 2025 se distingue de 2021-2024 casi por completo.
La etiqueta de lo más reciente madura tarde (censura al final del periodo).
Maestros en foto actual, no con su vigencia histórica.
Arranque en frío: 11,1 % de proveedores nuevos en 2026.
Una sola empresa: la generalización a otros grupos no está probada.

Mejoras

Reentrenar por semestre y vigilar la deriva con la validación adversaria.
Efectos aleatorios por proveedor y material para el arranque en frío.
Usar los días de retraso con cortes ordenados (el modelo original del Entregable 3).
Maestros con vigencia por fecha.

Fuente: libro, capítulos 4, 6 y 9



Preguntas

Repositorio github.com/ddcarbono/otif-compras-ml

Libro ddcarbono.github.io/otif-compras-ml

Tablero otif-compras-ml.onrender.com

Responden los dos autores (criterio 7: dominio individual).