UNIVERSIDAD DEL NORTE

Maestría en Estadística Aplicada

Machine Learning

Daniel Carbonó Domínguez

Luis Pérez

Octubre de 2026

ENTREGABLE 2 · CLASIFICACIÓN BINARIA SUPERVISADA

Predicción del incumplimiento de órdenes de compra en la agroindustria de la palma de aceite

406.126 posiciones de 104.614 órdenes de compra, 2021-2026

Repositorio github.com/ddcarbono/otif-compras-ml

Libro ddcarbono.github.io/otif-compras-ml

Tablero otif-compras-ml.onrender.com

Uno de cada tres pedidos llega tarde, y se sabe cuando ya pasó

CRITERIO 1 · PROBLEMA Y FORMULACIÓN

33,0 %
de las posiciones llega tarde

1 día
hábil de tolerancia sobre la fecha prometida

Objetivo

Ordenar las posiciones por riesgo el día de la liberación y señalar cuáles seguir primero.

Unidad: la posición i de una orden

$$x_i \in \mathbb{R}^{136}, \quad y_i \in \{0, 1\}$$

x: 136 predictoras conocidas el día t en que la orden sale al proveedor. y = 1 si la primera entrada llega más de 1 día hábil después de la fecha prometida.

$$p(x) = P(y = 1 \mid x), \qquad \hat{y} = \mathbb{1}\{\hat{p}(x) \geq \tau\}$$

Se estima la probabilidad p(x) y se decide con un umbral τ, elegido en la validación 2025 maximizando F1; la prueba 2026 no elige nada.

Por qué clasificación binaria

La decisión del comprador es una sola: hacerle seguimiento a la orden o no. Los días de retraso tienen colas largas y se usan como contexto, no como objetivo.

Objetivos específicos

1. Comparar 7 modelos × 4 formas de balancear × 4 optimizadores con el mismo presupuesto.
2. Medir cuánto cuesta decidir con entidades nuevas: proveedor o material sin historia.
3. Dejar el modelo servido en un tablero con la predicción en vivo.

Fuente: libro, capítulos 1 y 2a (definición de la etiqueta y de la población)

De SAP a 406.126 posiciones con una etiqueta y 136 predictoras

CRITERIO 2 · FUENTE, ESTRUCTURA Y PARTICIÓN

SAP
compras 2021-2026

490.310
posiciones con plazo

406.126
población

etiqueta
> 1 día hábil tarde

136
predictoras al liberar

partición	uso	posiciones	órdenes	tarde
2021-2024	entrenar	271.391	70.233	34,0 %
2025	elegir umbral	82.794	21.797	30,8 %
2026	probar una vez	51.941	12.584	31,5 %

Las órdenes son la unidad independiente: 3,9 posiciones por orden. Ninguna orden cruza particiones y toda validación cruzada agrupa por orden.

La partición es por la fecha de la orden, no al azar (lámina 5).

Las 136 predictoras

83 numéricas: plazo, valor, liberación, historial del proveedor, stock, tasa de cambio.
42 categóricas de pocos valores: línea, clase, moneda, tipo de material.
11 entidades: proveedor, material, comprador, liberador, centro de costo y otras.
Solo lo que se conoce el día de la liberación.

Fuente: libro, capítulo 2a (datos); diccionario de variables en data/diccionario.csv

Ninguna variable sola pasa de 0,75 de AUC

CRITERIO 2 · DESCRIPTIVA, FALTANTES, ATÍPICOS Y RELACIONES



El plazo hábil al liberar separa más (0,732): es la causa más directa del retraso y se conoce al liberar; no es fuga.

Faltantes estructurales

7 variables con más de 50 % de vacíos, y no son azar: faltan porque la orden no tiene solicitud o no tiene imputación. Se marcan con indicadores tiene_* y se imputa la mediana.

Atípicos (Isolation Forest)

40,4 % de tarde en las atípicas contra 33,7 % en el resto: son señal, no ruido, y no se borran.

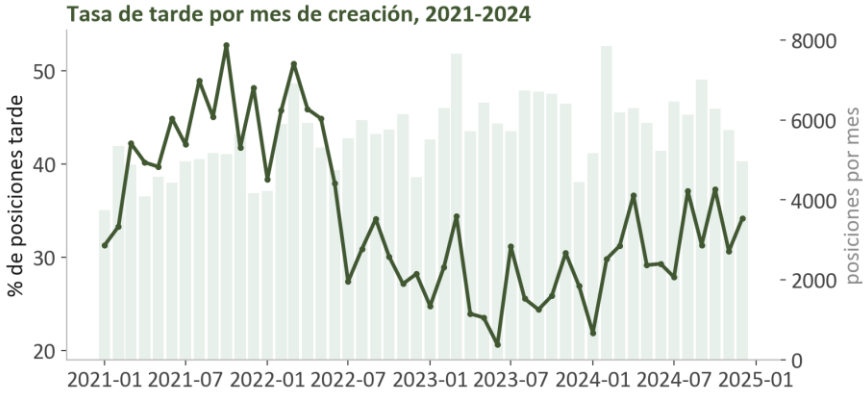
Colas largas

Valor, cantidad y plazos son muy asimétricos: signo(x)·log(1 + |x|) antes de los modelos lineales; a los árboles no les cambia nada.

Fuente: libro, capítulo 2b (EDA): resultados/eda/asociacion.csv, faltantes.csv, atipicos_if.csv

El tiempo importa: partir al azar mediría con datos ya vistos

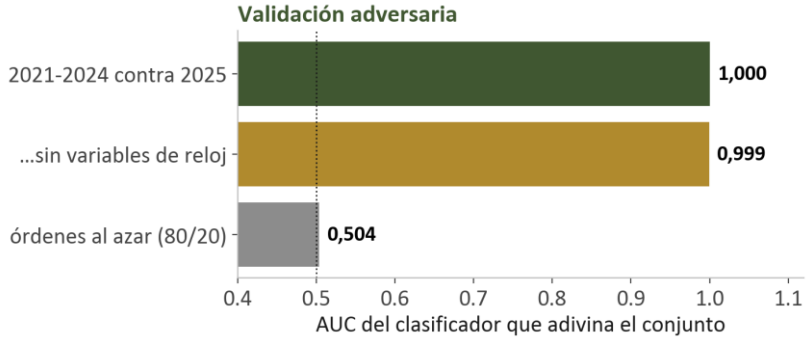
CRITERIO 2 · TIEMPO Y FUGA



No es estacionaria: ADF no rechaza la raíz unitaria (p = 0,70) y KPSS rechaza la estacionariedad (p = 0,026). Proveedores nuevos: 6,6 % en 2025 y 11,1 % en 2026.

Entidades: codificación fuera de pliegue, por orden

$$\hat{p}(v) = \frac{\text{retrasos}(v) + M\hat{p}(\text{padre}(v))}{n(v) + M}, \qquad M = 20$$



Validación adversaria: un XGBoost intenta adivinar de qué conjunto viene cada posición.

Al azar no puede (0,504). Por fecha acierta siempre (1,000), y sigue en 0,999 sin las variables que fechan la fila: muchas derivas pequeñas (IVA, región del centro, mezcla de líneas) bastan para reconocer el año.

Por eso: partición cronológica, validación por ventanas crecientes y reentrenar con 2021-2025 antes de la prueba.

Fuente: libro, capítulo 2c (tiempo y fuga): resultados/eda/ y resultados/similitud/auc.csv

XGBoost suma árboles; cada uno es un paso de Newton

CRITERIO 3 · FORMULACIÓN, PÉRDIDA Y OPTIMIZACIÓN

El modelo: el log-odds es una suma de M árboles

$$F(x) = \sum_{m=1}^{M} f_m(x), \qquad \hat{p}(x) = \sigma(F(x)) = \frac{1}{1+e^{-F(x)}}$$

La pérdida: log-pérdida (entropía cruzada binaria), convexa en F

$$\ell(y, F) = -y \log \sigma(F) - (1-y)\log(1-\sigma(F))$$

El objetivo del árbol m: pérdida más penalización de su complejidad

$$\mathcal{L}^{(m)} = \sum_{i=1}^{n} \ell(y_i,\, F_{m-1}(x_i) + f(x_i)) + \gamma T + \tfrac{1}{2}\lambda \sum_{j=1}^{T} w_j^2$$

Taylor de segundo orden alrededor de la predicción actual

$$\mathcal{L}^{(m)} \approx \sum_{i} \left[g_i f(x_i) + \tfrac{1}{2} h_i f(x_i)^2 \right] + \gamma T + \tfrac{1}{2}\lambda \sum_{j} w_j^2$$

$$g_i = \hat{p}_i - y_i, \qquad h_i = \hat{p}_i\,(1-\hat{p}_i)$$

Qué es cada término

- **f_m**
  un árbol de regresión: reparte x en T hojas con pesos w_j.
- **σ**
  la logística: pasa el log-odds F a probabilidad.
- **γ T**
  cobra por cada hoja; λ encoge los pesos hacia 0 (L2).
- **g_i**
  gradiente: el residuo con signo, p̂ − y.
- **h_i**
  hessiano: varianza de Bernoulli, alta donde el modelo duda.

Fuente: libro, capítulo 7 (fundamentos de XGBoost); Chen y Guestrin (2016), Friedman (2001)

Peso de hoja y ganancia de corte en forma cerrada

CRITERIO 3 · PRINCIPIO DE OPTIMIZACIÓN

Peso óptimo de la hoja j

$$w_j^* = -\frac{G_j}{H_j + \lambda}$$

Con G_j y H_j la suma de g y h en la hoja, la aproximación es una parábola en w_j: su mínimo es un paso de Newton, el gradiente sobre la curvatura, encogido por λ.

Búsqueda por histograma (hist)

Cada predictora se discretiza en a lo sumo 256 tramos y la ganancia se evalúa solo en sus bordes: buscar el mejor corte es recorrer un histograma, no ordenar las filas.

Ganancia de partir una hoja en izquierda (L) y derecha (R): se corta solo si es positiva

$$\text{ganancia} = \frac{1}{2}\left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda}\right] - \gamma$$

Paso corto: cada árbol entra encogido por la tasa de aprendizaje

$$F_m = F_{m-1} + \eta f_m$$

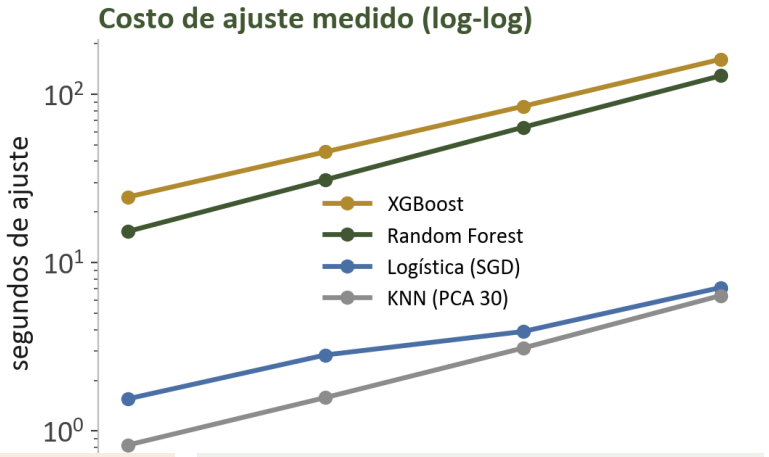
Contraste: la logística minimiza la misma log-pérdida con una sola recta, convexa y con un único óptimo. No ve interacciones ni umbrales sin construirlos; XGBoost los encuentra con los cortes.

Fuente: libro, capítulo 7; Chen y Guestrin (2016)

El ajuste crece casi lineal en n (exponente 0,91)

CRITERIO 3 · SUPUESTOS, REGULARIZACIÓN, COMPLEJIDAD Y GENERALIZACIÓN

hiperparámetro	en la fórmula	qué controla
n_estimators	M	capacidad y costo
learning_rate	η	pasos cortos, mejor generalización
max_depth	T ≤ 2^D	interacciones de hasta D variables
min_child_weight	H_j ≥ c	hojas con suficiente evidencia
subsample, colsample	filas y columnas	azar que decorrelaciona árboles
reg_lambda, gamma	λ, γ	encoge pesos, cobra hojas



Supuestos

Filas independientes dado x (por eso los pliegues agrupan por orden); la relación de 2021-2025 sigue valiendo en 2026; no supone linealidad ni normalidad.

Complejidad

Ajuste O(M·D·n·d') por histograma; predicción O(M·D). Medido: 162 s con 311.865 filas; 16,8 ms por cada 1.000 predicciones.

Generalización

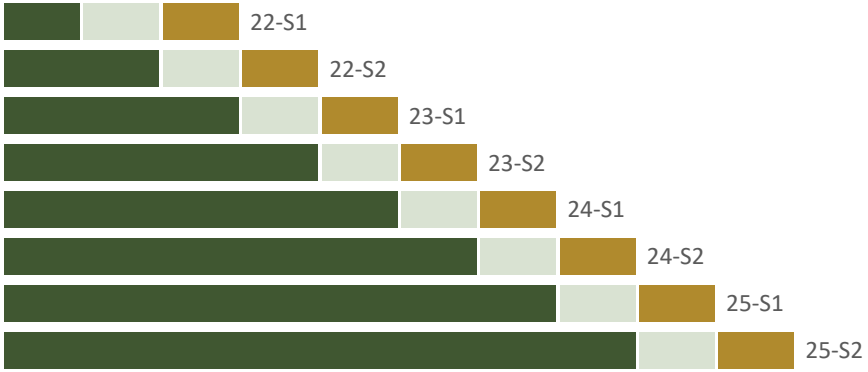
Parada por presupuesto y validación por ventanas en el tiempo; una entidad nueva recibe la tasa de su nivel superior.

Fuente: libro, capítulo 7: resultados/complejidad.csv (tiempos medidos en srvgdai)

Hacia adelante en el tiempo, con el mismo presupuesto

CRITERIO 4 · DISEÑO EXPERIMENTAL E IMPLEMENTACIÓN

$$7 \times 4 \times 4 = 112 \text{ combinaciones} \times 8 \text{ bloques} = 896 \text{ trabajos}$$



verde: entrena gris: valida adentro (elige hiperparámetros) **oro: evalúa (bucle externo)**

4 balanceos: ninguno, SMOTE, ADASYN y pesos de clase, siempre dentro del pipeline y solo sobre el entrenamiento. 20 evaluaciones por optimizador y bloque. Total: 201 horas de CPU en un servidor del grupo (srvgdai), con 30 trabajos a la vez.

Reproducibilidad

Un script por paso en src/; semilla 2026 en todo.
Preprocesador sin hiperparámetros, ajustado una vez por ventana.
57 pruebas con pytest e integración continua en GitHub.
Cada trabajo deja su JSON con parámetros y métricas.

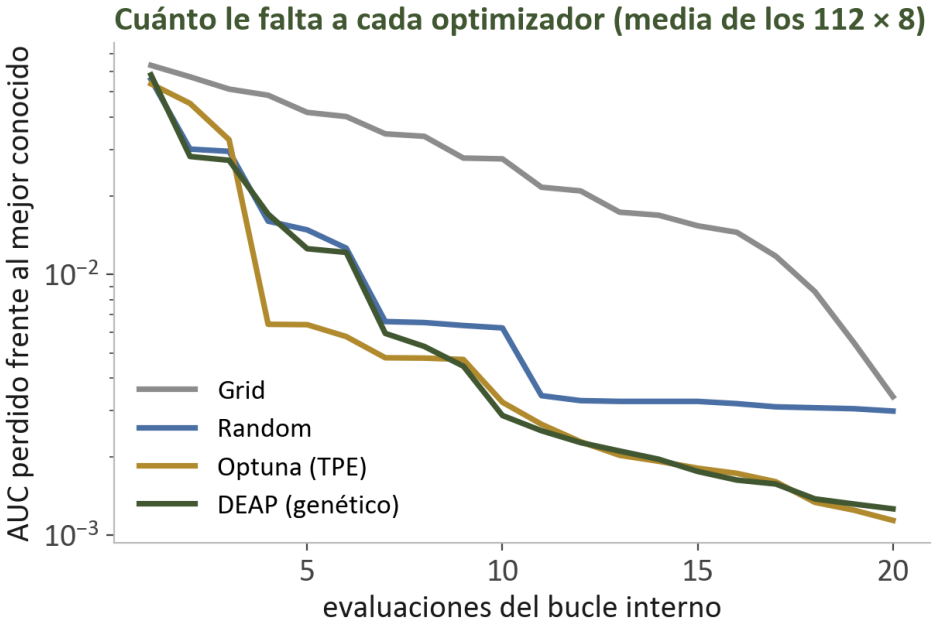
Decisiones computacionales

Matrices preprocesadas en float32 leídas con mmap, para correr 30 trabajos a la vez; SMOTE y ADASYN calculados una vez por ventana; KNN sobre 30 componentes principales.

Fuente: libro, capítulo 5 (las 112): src/validacion.py, src/experimentos.py, tests/

Optuna llega antes; con 20 evaluaciones empatan los cuatro

CRITERIO 4 · HIPERPARÁMETROS Y OPTIMIZADORES



optimizador	AUC perdido a 5 evaluaciones	a 20
Optuna	0,0064	0,0011
DEAP	0,0125	0,0013
Random	0,0148	0,0030
Grid	0,0417	0,0034

Optuna (TPE)

Modela qué zonas del espacio dieron buen AUC y propone donde la mejora esperada es mayor: aprende de los ensayos anteriores.

DEAP (genético)

Selección, cruce, mutación y elitismo sobre una población de configuraciones; llega tarde pero llega.

Fuente: libro, capítulo 5: data/modelos/curvas_optimizador.csv

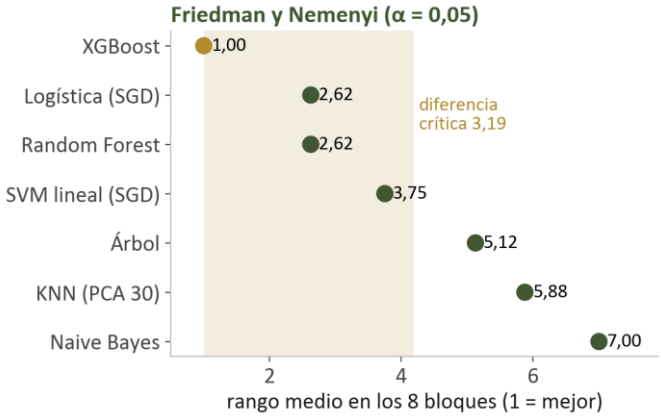
XGBoost gana los 8 bloques: AUC 0,852 contra 0,843

CRITERIO 5 · MÉTRICAS, LÍNEA BASE Y COMPARACIÓN

modelo (mejor combinación)	AUC ± desv.	PR-AUC	F1	ms / 1.000
XGBoost · sin balanceo · Optuna	0,852 ± 0,020	0,778	0,676	17,3
Random Forest · SMOTE · Grid	0,843 ± 0,023	0,761	0,660	31,8
Logística (SGD) · pesos · Grid	0,839 ± 0,025	0,751	0,663	0,7
SVM lineal (SGD) · pesos · Random	0,839 ± 0,024	0,749	0,659	0,7
Árbol · sin balanceo · Optuna	0,810 ± 0,020	0,715	0,634	0,8
KNN (PCA 30) · SMOTE · Optuna	0,781 ± 0,044	0,665	0,601	1.414,6
Naive Bayes · SMOTE · DEAP	0,735 ± 0,069	0,566	0,556	29,4

Métricas: AUC ordena por riesgo (independiente del umbral), PR-AUC atiende a la clase de interés, F1 mide la decisión al umbral; Brier y ECE, si la probabilidad es creíble.

prueba 2026 (línea base)	AUC	F1	Brier
regla del proveedor	0,670	0,509	0,202
regresión logística	0,825	0,649	0,149



Friedman: $\chi^2 = 45{,}6$, $p < 0{,}001$.

Nemenyi no separa a XGBoost de la logística ni del bosque (diferencia crítica 3,19); Wilcoxon por pares sí: gana los 8 bloques, p de Holm = 0,047.

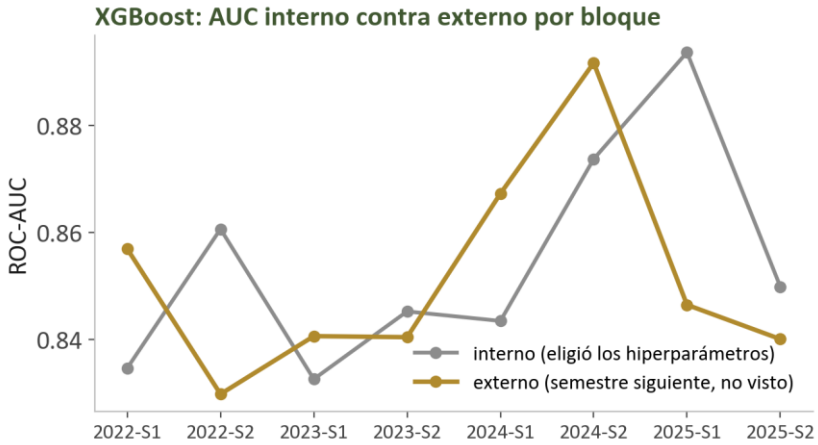
Pendiente: evaluación final 2026

XGBoost en la prueba 2026 y la tabla de brecha validación-prueba de cada modelo.

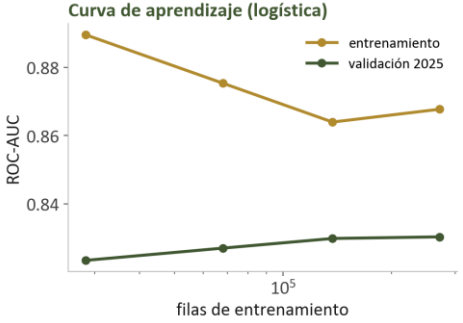
Fuente: libro, capítulos 4 y 5: data/modelos/lideres.csv, friedman.csv, wilcoxon.csv, metricas.csv

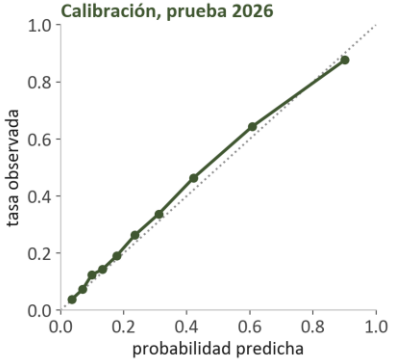
Sobreajuste bajo: 0,003 de AUC entre interno y externo

CRITERIO 5 · ANÁLISIS DE ERRORES Y SOBREAJUSTE



El bloque 2025-S1 baja de 0,894 adentro a 0,846 afuera: es el semestre en que cambia la mezcla de 2025 (lámina 5), no un modelo que memoriza.





Logística (modelo base): 0,868 en entrenamiento y 0,830 en validación con todas las filas; bien calibrada en 2026 (ECE 0,021).

Pendiente: evaluación final 2026

para el mejor modelo en 2026: matriz de confusión por línea de negocio, errores con entidades nuevas frente a conocidas, un falso negativo típico y SHAP (qué variables mueven cada predicción).

Fuente: libro, capítulos 4 y 5: resultados/experimentos/por_bloque.csv, data/modelos/curva_aprendizaje.csv

El retraso se anticipa al liberar, con límites claros

CRITERIO 6 · CONCLUSIONES Y LIMITACIONES

Conclusiones

- Se puede ordenar por riesgo al liberar: AUC 0,852 hacia adelante en el tiempo, contra 0,670 de la regla del proveedor en 2026.
- La señal está en el plazo, el historial del proveedor y las entidades; ninguna variable sola basta.
- XGBoost gana, pero por una centésima: la logística, más simple y calibrada, queda como alternativa defendible.
- El optimizador importa con poco presupuesto; el balanceo casi no mueve el AUC.

Limitaciones y mejoras

- Deriva: 2025 se distingue de 2021-2024 casi por completo; hay que reentrenar y vigilar.
- La etiqueta de lo más reciente madura tarde (censura al final del periodo).
- Maestros en foto actual, no con su vigencia histórica.
- Una sola empresa: la generalización a otros grupos no está probada.
- Arranque en frío: 11,1 % de proveedores nuevos en 2026.

Fuente: libro, capítulos 2 a 7



Preguntas

Repositorio github.com/ddcarbono/otif-compras-ml

Libro ddcarbono.github.io/otif-compras-ml

Tablero otif-compras-ml.onrender.com

Responden los dos autores (criterio 7: dominio individual).